Dron zwiadowczy w środowisku gridowym

Projekt z przedmiotu *Uczenie się ze wzmocnieniem*, 2026/2027

Nicolas Liszek 179552
Politechnika Rzeszowska, WEiI

9 listopada 2026

Streszczenie

Projekt dotyczy agenta sterującego dronem zwiadowczym w dyskretnym środowisku gridowym. Agent ma sfotografować zestaw celów i wrócić do bazy przy ograniczonym zapasie energii, omijając strefy radarowe i ruchomy patrol. Wybór kolejności celów wpływa na dalszy przebieg misji, ponieważ sfotografowanie jednego z nich zamyka korytarz na mapie. Porównane zostaną agenty bazowe (losowy i zachłanny) z agentami tablicowymi (Q-learning, SARSA, Q(λ)).

Spis treści

1 Opis problemu **1**

2 Uzasadnienie zastosowania uczenia się ze wzmocnieniem **2**

3 Formalizacja RL/MDP **3**
3.1 Agent i środowisko 3
3.2 Stan 3
3.3 Akcje 4
3.4 Przejście (pojedynczy krok interakcji) 4
3.5 Funkcja nagrody 4
3.6 Warunki zakończenia epizodu 5
3.7 Ograniczenia środowiska 5
3.8 Współczynnik dyskontowania 5
3.9 Miary sukcesu projektu 5
3.10 Elementy wymagające weryfikacji po pierwszych testach 5

4 Wsparcie AI **6**

1 Opis problemu

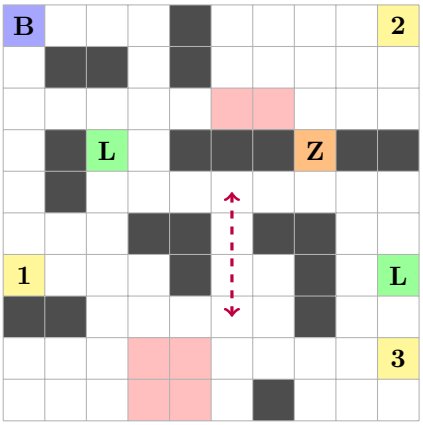
Repozytorium projektu. Projekt jest realizowany w publicznym repozytorium GitHub: `https://github.com/nickx64/rl-recon-drone`.

Dron zwiadowczy startuje z bazy umieszczonej na dwuwymiarowej mapie podzielonej na pola. Jego zadaniem jest wykonanie zdjęć K celów rozmieszczonych na mapie i powrót do bazy. Misję utrudniają:

- **ograniczona bateria** – każdy krok zużywa energię, a jej uzupełnienie jest możliwe wyłącznie na stacjach ładowania, które nie leżą na najkrótszych trasach między celami;
- **przeszkody statyczne** – budynki, przez które nie można przelecieć;

- **strefy radarowe** – przebywanie w nich skraca trasę, ale w każdym kroku grozi wykryciem drona i niepowodzeniem misji;
- **patrol** – przeszkoda dynamiczna poruszająca się cyklicznie po stałej trasie; kontakt z patrolem kończy misję;
- **zdarzenie zależne od decyzji agenta** – sfotografowanie celu nr 1 powoduje zamknięcie wybranego korytarza (pole Z), co może odciąć krótszą drogę do pozostałych celów.

Agent nie zna z góry modelu środowiska (prawdopodobieństwa wykrycia, skutków zdarzeń) – uczy się wyłącznie na podstawie interakcji. Projekt zakłada kilka map o rosnącej trudności (*easy*, *medium*, *hard*). Przykładową mapę pokazano na rys. 1.



Rysunek 1: Robocza mapa *easy* (10×10). B – baza, 1–3 – cele, L – stacje ładowania, czerwone pola – strefy radarowe, Z – korytarz zamykany po sfotografowaniu celu 1, czarne pola – przeszkody, fioletowa linia – trasa patrolu (ruch tam i z powrotem).

Dylemat zaprojektowany na mapie *easy*. Cel 1 leży najbliżej bazy (6 kroków), ale jego sfotografowanie zamyka korytarz Z. Po tym zdarzeniu jedyna droga do celu 2 prowadzi przez strefę radarową. Bezpieczna kolejność to $2 \to 3 \to 1 \to$ baza (ok. 46 kroków po trasach omijających radary), co przekracza pojemność baterii $E_{\max} = 30$ – agent musi więc dodatkowo zaplanować ładowanie. Strategia zachłanna („najpierw najbliższy cel") prowadzi natomiast do konieczności lotu przez radar. Wartości zmierzono algorytmem BFS na mapie z rys. 1, bez uwzględnienia patrolu.

Cel agenta. Wykonać zdjęcia wszystkich celów i wrócić do bazy w możliwie małej liczbie kroków, nie dopuszczając do wykrycia ani do rozładowania baterii.

2 Uzasadnienie zastosowania uczenia się ze wzmocnieniem

Problem nie jest zadaniem klasyfikacji ani jednorazowej optymalizacji, ponieważ:

1. **Decyzje są sekwencyjne** – misja składa się z kilkudziesięciu kroków, a jakość pojedynczego ruchu zależy od całej dalszej trajektorii.
2. **Decyzje zmieniają przyszły stan środowiska** – zużycie energii ogranicza dalsze możliwości, a sfotografowanie celu 1 trwale zmienia mapę (zamknięcie korytarza Z). Kolejność odwiedzania celów ma więc znaczenie, a zachłanne wybieranie najbliższego celu może prowadzić do sytuacji bez wyjścia.

3. **Występuje niepewność** – wykrycie w strefie radarowej jest zdarzeniem losowym, którego prawdopodobieństwo nie jest znane agentowi.

4. **Występuje konflikt celów** – krótsza trasa przez strefę radarową oznacza mniejsze zużycie energii, ale większe ryzyko; objazd jest bezpieczniejszy, ale może wymagać dodatkowego ładowania.

5. **Nagroda jest opóźniona** – główna nagroda za sukces pojawia się dopiero po powrocie do bazy, więc agent musi przypisać zasługę wcześniejszym decyzjom (np. odwiedzeniu stacji ładowania).

Te cechy odpowiadają klasycznemu sformułowaniu problemu decyzyjnego Markowa [2], w którym agent uczy się polityki maksymalizującej oczekiwany zdyskontowany zwrot bez znajomości modelu przejść.

3 Formalizacja RL/MDP

Problem modelujemy jako epizodyczny proces decyzyjny Markowa $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$.

3.1 Agent i środowisko

- **Agent** – dron; w każdym kroku wybiera jedną akcję.
- **Środowisko** – mapa $W \times H$ wraz z bazą, celami, stacjami ładowania, przeszkodami, strefami radarowymi, patrolem i korytarzem zamykanym. Środowisko przechowuje bieżący stan, wykonuje przejścia i zwraca nagrody.

3.2 Stan

Stan agenta to krotka

$$s = (x,\ y,\ e,\ m,\ \varphi), \tag{1}$$

gdzie:

- (x, y) – pozycja drona na mapie,
- $e \in \{0, 1, \ldots, E_{\max}\}$ – poziom baterii,
- $m \in \{0, 1\}^K$ – maska bitowa sfotografowanych celów,
- $\varphi \in \{0, \ldots, T_p - 1\}$ – faza patrolu ($\varphi = t \bmod T_p$, gdzie T_p to okres trasy patrolu).

Dlaczego faza patrolu jest w stanie? Pozycja patrolu zależy od czasu. Gdyby φ nie było częścią stanu, ten sam stan (x, y, e, m) prowadziłby do różnych skutków w zależności od chwili, w której agent się w nim znalazł – własność Markowa nie byłaby spełniona. Pozycję patrolu da się odtworzyć z φ, więc nie trzeba jej przechowywać osobno.

Dlaczego stan korytarza Z nie jest w stanie? Korytarz jest zamknięty dokładnie wtedy, gdy sfotografowano cel 1, czyli gdy $m_1 = 1$. Informacja ta jest już zawarta w masce m. Gdyby zdarzenie zależało od innego warunku (np. czasu), stan należałoby rozszerzyć o dodatkową flagę.

Rozmiar przestrzeni stanów. Górne oszacowanie wynosi

$$|\mathcal{S}| \leq W \cdot H \cdot (E_{\max} + 1) \cdot 2^K \cdot T_p. \tag{2}$$

Dla mapy *easy* (10×10, $E_{\max} = 30$, $K = 3$, $T_p = 6$) daje to $100 \cdot 31 \cdot 8 \cdot 6 = 148\,800$ stanów, a po uwzględnieniu $|\mathcal{A}| = 5$ około $7{,}4 \cdot 10^5$ wartości $Q(s, a)$. Taka tablica mieści się w pamięci (kilka MB), więc podejście tablicowe jest wykonalne. Faktycznie osiągalnych stanów jest mniej, ponieważ pola z przeszkodami nie są dostępne.

3.3 Akcje

$$\mathcal{A} = \{\text{GÓRA},\ \text{DÓŁ},\ \text{LEWO},\ \text{PRAWO},\ \text{CZEKAJ}\}.$$

- Ruch na pole poza mapą, na przeszkodę lub na zamknięty korytarz jest **akcją niepoprawną**: dron pozostaje na miejscu, zużywa energię i otrzymuje dodatkową karę.
- CZEKAJ na stacji ładowania zwiększa energię o Δ_L (do $E_{\max}$). Poza stacją oznacza zawis i zużywa energię jak ruch. Akcja ta pozwala też przeczekać przejście patrolu.

3.4 Przejście (pojedynczy krok interakcji)

W kroku t środowisko wykonuje kolejno:

1. wyznaczenie nowej pozycji na podstawie akcji a_t (z obsługą akcji niepoprawnych),
2. aktualizację energii: $e \leftarrow e - 1$ albo $e \leftarrow \min(e + \Delta_L, E_{\max})$ przy ładowaniu,
3. przesunięcie patrolu: $\varphi \leftarrow (\varphi + 1) \bmod T_p$,
4. sprawdzenie kolizji z patrolem (również „minięcia się” na sąsiednich polach, gdy dron i patrol zamieniają się miejscami),
5. jeżeli dron jest na niesfotografowanym celu i – ustawienie $m_i = 1$ (dla $i = 1$ zamknięcie korytarza Z),
6. jeżeli dron jest w strefie radarowej – losowanie wykrycia z prawdopodobieństwem p_{det},
7. sprawdzenie warunków zakończenia i zwrócenie $(s_{t+1}, r_{t+1}, \textit{terminated}, \textit{truncated})$.

Interfejs środowiska będzie zgodny z biblioteką Gymnasium [1] (`reset()`, `step(a)`).

3.5 Funkcja nagrody

Zdarzenie	Nagroda	Uzasadnienie
każdy krok	-1	zachęca do krótkich tras
akcja niepoprawna	-2 (dodatkowo)	zniechęca do „odbijania się” od ścian
sfotografowanie nowego celu	$+10$	nagroda pośrednia, ułatwia eksplorację
powrót do bazy ze wszystkimi celami	$+50$	główny cel misji
wykrycie, kolizja z patrolem	-50	porażka misji
rozładowanie baterii	-50	porażka misji

Tabela 1: Wstępna funkcja nagrody (wartości do strojenia po pierwszych testach).

Kara za porażkę (-50) jest celowo równa nagrodzie za sukces, aby agent nie wolał szybko zakończyć epizodu porażką zamiast długo latać z karą -1 za krok. Przy długości epizodu rzędu 40–60 kroków suma kar za kroki jest porównywalna z karą za porażkę – ten balans trzeba sprawdzić eksperymentalnie (zob. sekcja 3.10).

3.6 Warunki zakończenia epizodu

- **Sukces** (*terminated*): dron jest w bazie i $m = (1, \ldots, 1)$.
- **Porażka** (*terminated*): wykrycie w strefie radarowej, kolizja z patrolem lub $e = 0$ poza bazą.
- **Przekroczenie limitu** (*truncated*): $t \geq T_{\max}$.

Rozróżnienie *terminated*/*truncated* jest istotne przy aktualizacji wartości: po zakończeniu właściwym wartość stanu następnego wynosi 0, natomiast po obcięciu limitem kroków agent nadal powinien korzystać z oszacowania $\max_a Q(s_{t+1}, a)$.

3.7 Ograniczenia środowiska

- energia $E_{\max}$ (wstępnie 30) i przyrost ładowania Δ_L (wstępnie 5 na krok),
- limit kroków $T_{\max}$ (wstępnie 200),
- prawdopodobieństwo wykrycia p_{det} (wstępnie 0,3 na krok),
- brak możliwości wejścia na przeszkody i zamknięty korytarz.

3.8 Współczynnik dyskontowania

Wstępnie $\gamma = 0{,}99$. Główna nagroda pojawia się dopiero na końcu długiego epizodu, więc zbyt mała wartość γ sprawiłaby, że agent praktycznie nie odczuwałby nagrody za powrót do bazy. Wpływ γ zostanie sprawdzony w eksperymentach.

3.9 Miary sukcesu projektu

- odsetek misji zakończonych sukcesem (w fazie ewaluacji, bez eksploracji),
- średni zwrot z epizodu,
- średnia długość udanego epizodu,
- odsetek porażek z podziałem na przyczyny (wykrycie, patrol, bateria),
- stabilność wyników między uruchomieniami z różnym ziarnem losowym.

Projekt uznajemy za udany, jeżeli agent uczący się istotnie przewyższa agentów bazowych na wszystkich mapach, a zachowanie agenta (np. omijanie radarów, planowanie ładowania, kolejność celów) daje się zinterpretować.

3.10 Elementy wymagające weryfikacji po pierwszych testach

- wartości nagród – czy agent nie uczy się „samobójczych" polityk albo krążenia w miejscu,
- czy nagroda +10 za cel nie powoduje, że agent zbiera cele i nie wraca do bazy,
- wartość p_{det} – zbyt duża sprawi, że radary staną się zwykłymi ścianami, zbyt mała – że będą bez znaczenia,
- czy osiągalna przestrzeń stanów jest wystarczająco mała dla tablicowego Q-learningu na mapie *hard*,
- ewentualne dodanie losowego znoszenia drona przez wiatr (dodatkowe źródło niepewności).

4 Wsparcie AI

Literatura

[1] Farama Foundation. Gymnasium – an api standard for reinforcement learning environments. `https://gymnasium.farama.org`. Dostęp: 2026-11-08.

[2] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.