Raport projektowy
Uczenie się ze wzmocnieniem

Dron zwiadowczy w środowisku gridowym

Nicolas Liszek

2026/2027

Streszczenie

Projekt dotyczy agenta sterującego dronem zwiadowczym w dyskretnym środowisku gridowym. Agent ma sfotografować zestaw celów i wrócić do bazy przy ograniczonym zapasie energii, omijając strefy radarowe i ruchomy patrol. Wybór kolejności celów wpływa na dalszy przebieg misji, ponieważ sfotografowanie jednego z nich zamyka korytarz na mapie. Porównane zostaną agenty bazowe (losowy i zachłanny) z agentami tablicowymi (Q-learning, SARSA, Q(λ)).

Spis treści

1 Informacje podstawowe **2**

2 Temat i cel projektu **2**
2.1 Opis problemu 2
2.2 Cel agenta 3
2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem 3

3 Formalizacja problemu RL/MDP **4**
3.1 Agent i środowisko 4
3.2 Stan lub obserwacja 4
3.3 Akcje 5
3.4 Przejście (pojedynczy krok interakcji) 5
3.5 Funkcja nagrody 6
3.6 Warunki zakończenia epizodu 7
3.7 Założenia i ograniczenia środowiska 7
3.8 Współczynnik dyskontowania 8
3.9 Miary sukcesu projektu 8
3.10 Elementy wymagające weryfikacji po pierwszych testach 8

4 Wsparcie AI **8**

1 Informacje podstawowe

Element	Informacja
Imię i nazwisko	Nicolas Liszek
Numer albumu	179552
Kierunek/specjalność	Sztuczna Inteligencja
Tytuł projektu	Dron zwiadowczy w środowisku gridowym
Link do repozytorium	https://github.com/nickx64/rl-recon-drone
Data oddania	

2 Temat i cel projektu

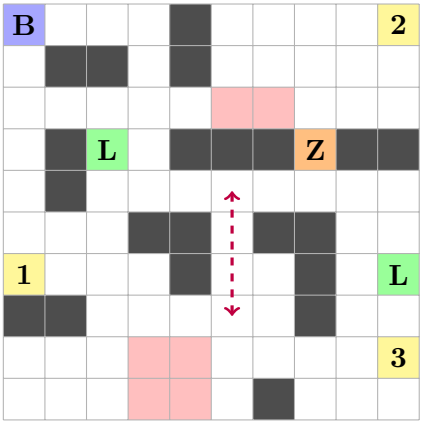
2.1 Opis problemu

Dron zwiadowczy startuje z bazy umieszczonej na dwuwymiarowej mapie podzielonej na pola. Jego zadaniem jest wykonanie zdjęć K celów rozmieszczonych na mapie i powrót do bazy. Misję utrudniają:

- **ograniczona bateria** – każdy krok zużywa energię, a jej uzupełnienie jest możliwe wyłącznie na stacjach ładowania, które nie leżą na najkrótszych trasach między celami;
- **przeszkody statyczne** – budynki, przez które nie można przelecieć;
- **strefy radarowe** – przebywanie w nich skraca trasę, ale w każdym kroku grozi wykryciem drona i niepowodzeniem misji;
- **patrol** – przeszkoda dynamiczna poruszająca się cyklicznie po stałej trasie; kontakt z patrolem kończy misję;
- **zdarzenie zależne od decyzji agenta** – sfotografowanie celu nr 1 powoduje zamknięcie wybranego korytarza (pole Z), co może odciąć krótszą drogę do pozostałych celów.

Agent nie zna z góry modelu środowiska (prawdopodobieństwa wykrycia, skutków zdarzeń) – uczy się wyłącznie na podstawie interakcji. Projekt zakłada kilka map o rosnącej trudności (*easy*, *medium*, *hard*). Przykładową mapę pokazano na rys. 1.

Dylemat zaprojektowany na mapie *easy*. Cel 1 leży najbliżej bazy (6 kroków), ale jego sfotografowanie zamyka korytarz Z. Po tym zdarzeniu jedyna droga do celu 2 prowadzi przez strefę radarową. Bezpieczna kolejność to $2 \to 3 \to 1 \to$ baza (ok. 46 kroków po trasach omijających radary), co przekracza pojemność baterii $E_{\max} = 30$ – agent musi więc dodatkowo zaplanować ładowanie. Strategia zachłanna („najpierw najbliższy cel") prowadzi natomiast do konieczności lotu przez radar. Wartości zmierzono algorytmem BFS na mapie z rys. 1, bez uwzględnienia patrolu.



Rysunek 1: Robocza mapa *easy* (10×10). B – baza, 1–3 – cele, L – stacje ładowania, czerwone pola – strefy radarowe, Z – korytarz zamykany po sfotografowaniu celu 1, czarne pola – przeszkody, fioletowa linia – trasa patrolu (ruch tam i z powrotem).

2.2 Cel agenta

Agent ma wykonać zdjęcia wszystkich celów i wrócić do bazy w możliwie małej liczbie kroków, nie dopuszczając do wykrycia, kolizji z patrolem ani do rozładowania baterii. Działanie agenta uznajemy za poprawne, jeżeli epizod kończy się sukcesem w rozumieniu sekcji 3.6, a za skuteczne – jeżeli w fazie ewaluacji (bez eksploracji) agent osiąga sukces w większości epizodów przy długości trasy zbliżonej do najkrótszej bezpiecznej trasy z ładowaniem. Szczegółowe miary podano w sekcji 3.9.

2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem

Problem nie jest zadaniem klasyfikacji ani jednorazowej optymalizacji, ponieważ:

1. **Decyzje są sekwencyjne** – misja składa się z kilkudziesięciu kroków, a jakość pojedynczego ruchu zależy od całej dalszej trajektorii.
2. **Decyzje zmieniają przyszły stan środowiska** – zużycie energii ogranicza dalsze możliwości, a sfotografowanie celu 1 trwale zmienia mapę (zamknięcie korytarza Z). Kolejność odwiedzania celów ma więc znaczenie, a zachłanne wybieranie najbliższego celu może prowadzić do sytuacji bez wyjścia.
3. **Występuje niepewność** – wykrycie w strefie radarowej jest zdarzeniem losowym, którego prawdopodobieństwo nie jest znane agentowi.
4. **Występuje konflikt celów** – krótsza trasa przez strefę radarową oznacza mniejsze zużycie energii, ale większe ryzyko; objazd jest bezpieczniejszy, ale może wymagać dodatkowego ładowania.
5. **Nagroda jest opóźniona** – główna nagroda za sukces pojawia się dopiero po powrocie do bazy, więc agent musi przypisać zasługę wcześniejszym decyzjom (np. odwiedzeniu stacji ładowania).

Te cechy odpowiadają klasycznemu sformułowaniu problemu decyzyjnego Markowa [2], w którym agent uczy się polityki maksymalizującej oczekiwany zdyskontowany zwrot bez znajomości modelu przejść.

3 Formalizacja problemu RL/MDP

Problem modelujemy jako epizodyczny proces decyzyjny Markowa $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$.

3.1 Agent i środowisko

- **Agent** – dron; w każdym kroku wybiera jedną akcję.
- **Środowisko** – mapa $W \times H$ wraz z bazą, celami, stacjami ładowania, przeszkodami, strefami radarowymi, patrolem i korytarzem zamykanym. Środowisko przechowuje bieżący stan, wykonuje przejścia i zwraca nagrody.

3.2 Stan lub obserwacja

Stan środowiska to krotka

$$s = (x,\ y,\ e,\ m,\ \varphi), \tag{1}$$

której składowe opisano w tabeli 1.

Składowa stanu/obserwacji	Znaczenie
(x, y)	pozycja drona na mapie
$e \in \{0, 1, \ldots, E_{\max}\}$	poziom baterii
$m \in \{0, 1\}^K$	maska bitowa sfotografowanych celów ($m_i = 1$ – cel i został sfotografowany)
$\varphi \in \{0, \ldots, T_p - 1\}$	faza patrolu, $\varphi = t \bmod T_p$, gdzie T_p to okres trasy patrolu

Tabela 1: Składowe stanu.

Stan a obserwacja. Agent obserwuje pełny stan s, więc problem jest w pełni obserwowalnym MDP. Agent nie dostaje natomiast informacji o modelu środowiska: nie zna układu mapy, trasy patrolu, wartości p_{det} ani skutków sfotografowania celu 1. Elementy te należą do dynamiki przejść P, a nie do stanu, i agent poznaje je wyłącznie pośrednio, przez obserwowane przejścia i nagrody. Pozycja patrolu nie jest podawana wprost, ponieważ wynika jednoznacznie z fazy φ.

Dlaczego faza patrolu jest w stanie? Pozycja patrolu zależy od czasu. Gdyby φ nie było częścią stanu, ten sam stan (x, y, e, m) prowadziłby do różnych skutków w zależności od chwili, w której agent się w nim znalazł – własność Markowa nie byłaby spełniona. Pozycję patrolu da się odtworzyć z φ, więc nie trzeba jej przechowywać osobno.

Dlaczego stan korytarza Z nie jest w stanie? Korytarz jest zamknięty dokładnie wtedy, gdy sfotografowano cel 1, czyli gdy $m_1 = 1$. Informacja ta jest już zawarta w masce m. Gdyby zdarzenie zależało od innego warunku (np. czasu), stan należałoby rozszerzyć o dodatkową flagę.

Rozmiar przestrzeni stanów. Górne oszacowanie wynosi

$$|\mathcal{S}| \leq W \cdot H \cdot (E_{\max} + 1) \cdot 2^K \cdot T_p. \tag{2}$$

Dla mapy *easy* (10×10, $E_{\max} = 30$, $K = 3$, $T_p = 6$) daje to $100 \cdot 31 \cdot 8 \cdot 6 = 148\,800$ stanów, a po uwzględnieniu $|\mathcal{A}| = 5$ około $7{,}4 \cdot 10^5$ wartości $Q(s, a)$. Taka tablica mieści się w pamięci (kilka MB), więc podejście tablicowe jest wykonalne. Faktycznie osiągalnych stanów jest mniej, ponieważ pola z przeszkodami nie są dostępne.

3.3 Akcje

$$\mathcal{A} = \{\text{GÓRA}, \text{DÓŁ}, \text{LEWO}, \text{PRAWO}, \text{CZEKAJ}\}.$$

Akcja	Opis
GÓRA	ruch o jedno pole w górę
DÓŁ	ruch o jedno pole w dół
LEWO	ruch o jedno pole w lewo
PRAWO	ruch o jedno pole w prawo
CZEKAJ	pozostanie na miejscu; na stacji ładowania zwiększa energię o Δ_L (do $E_{\max}$), poza stacją oznacza zawis i zużywa energię jak ruch; pozwala przeczekać przejście patrolu

Tabela 2: Zbiór akcji agenta.

Wszystkie akcje są dostępne w każdym stanie, dzięki czemu zbiór $\mathcal{A}$ jest stały, a tablica Q ma prostą strukturę. Ruch na pole poza mapą, na przeszkodę lub na zamknięty korytarz jest **akcją niepoprawną**: dron pozostaje na miejscu, zużywa energię i otrzymuje dodatkową karę.

3.4 Przejście (pojedynczy krok interakcji)

W kroku t środowisko wykonuje kolejno:

1. wyznaczenie nowej pozycji na podstawie akcji a_t (z obsługą akcji niepoprawnych),
2. aktualizację energii: $e \leftarrow e - 1$ albo $e \leftarrow \min(e + \Delta_L, E_{\max})$ przy ładowaniu,
3. przesunięcie patrolu: $\varphi \leftarrow (\varphi + 1) \bmod T_p$,
4. sprawdzenie kolizji z patrolem (również „minięcia się" na sąsiednich polach, gdy dron i patrol zamieniają się miejscami),
5. jeżeli dron jest na niesfotografowanym celu i – ustawienie $m_i = 1$ (dla $i = 1$ zamknięcie korytarza Z),
6. jeżeli dron jest w strefie radarowej – losowanie wykrycia z prawdopodobieństwem p_{det},
7. sprawdzenie warunków zakończenia i zwrócenie $(s_{t+1}, r_{t+1}, \textit{terminated}, \textit{truncated})$.

Interfejs środowiska będzie zgodny z biblioteką Gymnasium [1] (`reset()`, `step(a)`).

3.5 Funkcja nagrody

Nagroda otrzymana po wykonaniu akcji a_t w stanie s_t wynosi

$$r_{t+1} = -1 - 2 \cdot \mathbf{1}[\text{akcja niepoprawna}] + 10 \cdot \mathbf{1}[\text{nowy cel}] + 50 \cdot \mathbf{1}[\text{sukces}] - 50 \cdot \mathbf{1}[\text{porażka}], \quad (3)$$

gdzie $\mathbf{1}[\cdot]$ jest funkcją wskaźnikową, a zdarzenia i uzasadnienie wartości zebrano w tabeli 3.

Zdarzenie	Nagroda	Uzasadnienie
każdy krok	-1	zachęca do krótkich tras
akcja niepoprawna	-2 (dodatkowo)	zniechęca do „odbijania się” od ścian
sfotografowanie nowego celu	$+10$	nagroda pośrednia, ułatwia eksplorację
powrót do bazy ze wszystkimi celami	$+50$	główny cel misji
wykrycie, kolizja z patrolem	-50	porażka misji
rozładowanie baterii	-50	porażka misji

Tabela 3: Wstępna funkcja nagrody (wartości do strojenia po pierwszych testach).

Kara za krok. Kara -1 za każdy krok, także za ładowanie i zawis, sprawia, że krótsza trasa daje wyższy zwrot. Udana misja na mapie *easy* (ok. 50 kroków razem z ładowaniem) daje zwrot około $-50 + 3 \cdot 10 + 50 = +30$, czyli wyraźnie więcej niż dowolna porażka.

Ograniczenia twarde i miękkie. Ograniczenia *twarde* są narzucone przez środowisko niezależnie od nagrody: granice mapy, przeszkody i zamknięty korytarz Z (ruch jest niemożliwy) oraz rozładowanie baterii, kolizja z patrolem i limit kroków (koniec epizodu). Ograniczeniem *miękkim* są strefy radarowe: wejście do nich jest dozwolone, ale wiąże się z ryzykiem wykrycia, a o tym, czy skrót się opłaca, agent decyduje na podstawie oczekiwanego zwrotu. Miękka jest także kara -2 za akcję niepoprawną – zniechęca do niej, ale jej nie zabrania.

Czy nagroda nie zachęca do niepożądanego zachowania?

- Nagroda $+10$ jest przyznawana tylko za *nowy* cel (m_i zmienia się z 0 na 1), więc nie da się jej zbierać wielokrotnie, krążąc wokół celu.
- Ładowanie nie jest nagradzane, więc agent nie ma powodu ładować się ponad potrzebę.
- Zebranie celów bez powrotu kończy się porażką lub obcięciem epizodu, więc powrót do bazy zawsze się opłaca.
- **Ryzyko: porażka może być atrakcyjniejsza niż długie przetrwanie.** Agent, który nie potrafi jeszcze ukończyć misji i krąży (np. ładując się na stacji) aż do limitu $T_{\max} = 200$, uzyskuje zwrot około -200, natomiast szybkie wejście w strefę radarową kończy się zwrotem rzędu -55. Suma kar za kroki może więc przewyższyć karę za porażkę i na wczesnym etapie uczenia agent może nauczyć się celowego

kończenia epizodu. Możliwe przeciwdziałania to zmniejszenie kary za krok (np. do $-0{,}1$), zwiększenie kary za porażkę albo skrócenie $T_{\max}$. Wybór zostanie dokonany po pierwszych testach (zob. sekcja 3.10).

3.6 Warunki zakończenia epizodu

- **Sukces** (*terminated*): dron jest w bazie i $m = (1, \ldots, 1)$.
- **Porażka** (*terminated*): wykrycie w strefie radarowej, kolizja z patrolem lub $e = 0$ poza bazą.
- **Przekroczenie limitu** (*truncated*): $t \geq T_{\max}$.

Rozróżnienie *terminated*/*truncated* jest istotne przy aktualizacji wartości: po zakończeniu właściwym wartość stanu następnego wynosi 0, natomiast po obcięciu limitem kroków agent nadal powinien korzystać z oszacowania $\max_a Q(s_{t+1}, a)$.

3.7 Założenia i ograniczenia środowiska

Uproszczenia modelu.

- Przestrzeń jest dyskretna (siatka), dron porusza się w czterech kierunkach o jedno pole; pominięto wysokość lotu, prędkość i bezwładność.
- Każdy krok trwa tyle samo i kosztuje tyle samo energii, niezależnie od kierunku oraz od tego, czy dron leci, czy wisi w miejscu.
- Ruch jest deterministyczny – nie modelujemy wiatru ani błędów sterowania (wiatr jest rozważany jako rozszerzenie).
- Zdjęcie jest wykonywane automatycznie i natychmiast po wejściu na pole celu; pominięto orientację kamery i warunki widoczności.
- Wykrycie w strefie radarowej to niezależne losowanie w każdym kroku ze stałym prawdopodobieństwem p_{det}, bez zależności od odległości od radaru ani czasu przebywania w strefie.
- Występuje jeden patrol poruszający się po stałej, cyklicznej trasie, który nie reaguje na drona.
- Mapa jest statyczna z wyjątkiem korytarza Z; stacje ładowania mają nieograniczoną pojemność i stałe tempo ładowania.
- Agent obserwuje pełny stan – pominięto szum czujników i ograniczone pole widzenia.

Parametry środowiska.

- energia $E_{\max}$ (wstępnie 30) i przyrost ładowania Δ_L (wstępnie 5 na krok),
- limit kroków $T_{\max}$ (wstępnie 200),
- prawdopodobieństwo wykrycia p_{det} (wstępnie 0,3 na krok),
- brak możliwości wejścia na przeszkody i zamknięty korytarz.

3.8 Współczynnik dyskontowania

Wstępnie $\gamma = 0{,}99$. Główna nagroda pojawia się dopiero na końcu długiego epizodu, więc zbyt mała wartość γ sprawiłaby, że agent praktycznie nie odczuwałby nagrody za powrót do bazy. Wpływ γ zostanie sprawdzony w eksperymentach.

3.9 Miary sukcesu projektu

- odsetek misji zakończonych sukcesem (w fazie ewaluacji, bez eksploracji),
- średni zwrot z epizodu,
- średnia długość udanego epizodu,
- odsetek porażek z podziałem na przyczyny (wykrycie, patrol, bateria),
- stabilność wyników między uruchomieniami z różnym ziarnem losowym.

Projekt uznajemy za udany, jeżeli agent uczący się istotnie przewyższa agentów bazowych na wszystkich mapach, a zachowanie agenta (np. omijanie radarów, planowanie ładowania, kolejność celów) daje się zinterpretować.

3.10 Elementy wymagające weryfikacji po pierwszych testach

- wartości nagród – czy agent nie uczy się „samobójczych" polityk albo krążenia w miejscu; w szczególności bilans kary za krok i kary za porażkę (sekcja 3.5),
- czy nagroda +10 za cel nie powoduje, że agent zbiera cele i nie wraca do bazy,
- wartość p_{det} – zbyt duża sprawi, że radary staną się zwykłymi ścianami, zbyt mała – że będą bez znaczenia,
- czy osiągalna przestrzeń stanów jest wystarczająco mała dla tablicowego Q-learningu na mapie *hard*,
- ewentualne dodanie losowego znoszenia drona przez wiatr (dodatkowe źródło niepewności).

4 Wsparcie AI

Literatura

[1] Farama Foundation. Gymnasium – an api standard for reinforcement learning environments. https://gymnasium.farama.org. Dostęp: 2026-11-08.

[2] Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.